



Graph-based RAG

Lab Seminar

2026. 4. 27.(월)

서울대학교 산업공학과
데이터과학 및 비즈니스 애널리틱스 연구실
박사과정 김도윤

Contents

1. Introduction
2. Paper Review
 - 1) LightRAG: Simple and Fast Retrieval-Augmented Generation (EMNLP 2025)
 - 2) LeanRAG: Knowledge-Graph-Based Generation with Semantic Aggregation and Hierarchical Retrieval (AAAI-26)
3. Conclusion

1

Introduction

GraphRAG: Graph-based RAG의 서막

- Text corpus를 지식 그래프로 표현한 후, 지식 그래프 대상으로 community detection 적용 후 summary를 이용한 RAG 시스템 구축
 - Text corpus의 전반적인 내용이 반영 되어야 만 답을 할 수 있는 경우에 큰 강점을 보임
 - ex. What are the main themes in the dataset?, What are the key trends in how scientific discoveries are influenced by interdisciplinary research over the past decade?
- Graph-based RAG의 본격적인 시작

김도윤 세미나 자료 中 GNN4NLP

Paper Review

From Local to Global: A GraphRAG Approach to Query-Focused Summarization

Darren Edge and Ha Trinh et al., 2024 arxiv

서울대학교 산업공학과
데이터과학 및 비즈니스 애널리틱스 연구실
박사과정 김도윤

Heterogeneous Graph Neural Networks for Extractive Document Summarization (GNN4NLP)

Danqing Wang, Pengfei Liu, Yining Zheng, Xipeng Qiu, Xuanjing Huang, ACL 2020

DSBA

22. 8. 24 (수) 논문 세미나
고려대학교 DSBA 연구실 석박통합과정
김도윤

Introduction

Overview

GNN4NLP란?

- 기존의 자연어처리 과업들(ex. Text Classification/Generation, Question Answering, Knowledge Graph 등) 그래프 인공신경망(GNN, Graph Neural Network)으로 수행하는 것
- 언어, 문장 간 관계를 찾아내는 것이 중요한 과업에서(ex. Syntactic/ Semantic Relation) 강점을 보임
- 현재 자연어연구로 진행 중인 비지도학습 추출론(Unsupervised Keyphrase Extraction) 그래프 네트워크(GNN)를 사용하진 않지만, 그래프 및 그래프 네트워크에 재연계해 활용에 대한 공공용으로 관련 연구 장벽 등 해당 연구 분야 발전

Introduction

Overview

GNN4NLP

Fundamental: Text Classification, Sentiment Analysis (SA), Question Answering, Information Extraction, Text Generation, ...

Multi-hop Reasoning: Aspect-based SA, Multi-hop Reasoning, Relation Extraction, Summarization

NER

Related Work


Heterogeneous Graph Network in NLP

Multi-hop Reading Comprehension across Multiple Documents by Reasoning over Heterogeneous Graphs (Tu et al., 2019)

- Multi-hop Reading Comprehension: 여러 문단을 통해서 확인하는 과업
- 방법론 특징: Documents, entities, candidates의 노드들을 모두 한 번에 고려; GNN Layer를 거친 후 Candidates 중 하나를 답으로 선택하는 분류 진행 (Multi-Class Classification)
- 방법론 의미: 여러 종류의 노드를 함께 사용함으로써 노드 간의 관계에 대한 정보가 서로 잘 전달됨

Graph-based RAG

- 지식 그래프로 표현된 데이터 베이스를 활용한 검색 증강 생성 방식
 - 일반적인 그래프/네트워크 데이터도 가능하지만, 노드 간 관계의 정보가 포함되어 있을수록 더 의미 있는 검색 가능함



Graph-based RAG의 전반적인 과정

Vanilla RAG v.s. Graph-based RAG

- Vanilla RAG: 단순 Vector 기반의 RAG

비교 항목	Vanilla RAG	Graph-based RAG
지식 표현 방식	• 텍스트를 청크(chunk)로 분할 후 벡터 임베딩으로 변환 • 관계 정보 손실 • 초기 인덱싱의 구축 비용 비교적 낮음	• 노드와 관계로 구성된 지식 그래프로 저장 • 관계, 맥락 등 보존 • 그래프를 재구성하거나 새로운 정보를 기존의 노드/관계에 맞추어 추가
검색 방식	• 쿼리와 청크 간 벡터 유사도 기반 • 단순, 빠름	• 방법론 별 핵심이 되는 부분 ex) 서브 그래프 탐지 후 단순 나열, 커뮤니티 탐지 후 요약본 활용 등
응답 생성	• 단순 사실 질의에 빠르고 정확함	• 복잡한 상호의존 관계를 포착하여 맥락이 풍부함
적합한 상황	• 고객 지원 챗봇 - FAQ, 매뉴얼 등에서 즉시 답변 관련 내용 검색 필요 • 제품 설명서 QA - 단일 제품 사용 설명 챗봇	• 의학·신약 연구 분석 - 수 많은 논문에서의 약물-유전자-질환 관계 추론 • 법률 판례 분석 - 선례-법령의 인용 관계 추적 • 산업 트렌드 분석 - 기술경영관점에서의 기술 혁신을 위한 인사이트 도출

Research Questions

1. 어떻게 지식 그래프를 구축할 것인가?

- 이미 구축되어 있는 지식 그래프 활용
- LLM을 통해 프롬프트를 활용한 지식 그래프 내 triplet (SBJ-REL-OBJ) 추출

LightRAG 방법론 중 그래프 구축을 위한 프롬프트 예시

-Goal-

Given a text document that is potentially relevant to this activity and a list of entity types, identify all entities of those types from the text and all relationships among the identified entities.

-Steps-

1. Identify all entities. For each identified entity, extract the following information:

- **entity_name**: Name of the entity, capitalized
 - **entity_type**: One of the following types: [organization, person, geo, event]
 - **entity_description**: Comprehensive description of the entity's attributes and activities
- Format each entity as ("entity"<|><entity_name><|><entity_type><|><entity_description>)

2. From the entities identified in step 1, identify all pairs of (source_entity, target_entity) that are *clearly related* to each other.

For each pair of related entities, extract the following information:

- **source_entity**: name of the source entity, as identified in step 1
 - **target_entity**: name of the target entity, as identified in step 1
 - **relationship_description**: explanation as to why you think the source entity and the target entity are related to each other
 - **relationship_strength**: a numeric score indicating strength of the relationship between the source entity and target entity
 - **relationship_keywords**: one or more high-level key words that summarize the overarching nature of the relationship, focusing on concepts or themes rather than specific details
- Format each relationship as ("relationship"<|><source_entity><|><target_entity><|><relationship_description><|><relationship_keywords><|><relationship_strength>)

3. Identify high-level key words that summarize the main concepts, themes, or topics of the entire text. These should capture the overarching ideas present in the document.

Format the content-level key words as ("content_keywords"<|><high_level_keywords>)

4. Return output in English as a single list of all the entities and relationships identified in steps 1 and 2. Use ** as the list delimiter.**

5. When finished, output <|COMPLETE|>

-Real Data-

Entity_types: {entity_types}

Text: {input_text}

Output:


Graph Construct Prompt

Research Questions

2. 구축된 지식 그래프로부터 사용자 질의와 관련된 정보를 어떻게 추출할 것인가?

- Entity(노드) 활용
 - HippoRAG : 사용자 질의와 연관된 entity들을 검색한 후 일련의 과정을 거쳐 주요한 entity만 필터링한 후, entity 가 포함된 passage 활용
- Subgraph 활용
 - GraphRAG : Community detection 진행 후 community 별 요약문을 document로 활용
 - CausalRAG : 사용자 질의와 연관된 entity들을 검색한 후, s-hop으로 구성된 subgraph를 구축하는 경로에 대한 요약문 활용
- 기존의 지식 그래프에 모듈 추가
 - LightRAG : entity relation 각각을 이름-설명문의 key-value 로 재표현 후, 이를 document 로 활용
 - LeanRAG : GMM을 이용하여 노드들 간의 클러스터링 진행 후 상위에 클러스터 요약 노드를 구축함 / 수직적으로 연결된 노드들에 대한 정보 및 해당 entity가 포함된 passage 활용

대표 방법론 연구 흐름



Tasks and Evaluation

- Multi-hop QA
 - 문서 1, 문서 2 , ... 등 여러 번의 추론 단계를 거쳐서 답을 생성함
 - 답변의 정확한 평가: Exact Match, Recall 등
 - 검색된 context를 고려한 답변의 평가: RAGAs(2024) 평가 지표 활용

HotPot QA 데이터셋(Muti-hop QA) 의 예시

질문	문서 A	문서 B	답변	관련 context 번호
What was the former band of the member of MotherLove Bone who died just before the release of "Apple"?	[1] Return to Olympus is the only album by the alternative rock band Malfunkshun . [2] It was released after the band had broken up and after lead singer Andrew Wood (later of Mother Love Bone) had died of a drug over dose in 1990. [3] Stone Gossard, of Pearl Jam, had compiled the songs and released the album on his label, Loosegroove Records.	[4] Mother Love Bone was an American rock band that formed in Seattle, Washington in 1987. [5] The band was active from 1987 to 1990. [6] Frontman Andrew Wood's personality and compositions helped to catapult the group to the top of the burgeoning late 1980s/early 1990s Seattle music scene. [7] Wood died only days before the scheduled release of the band's debut album, "Apple", thus ending the group's hopes of success. [8] The album was finally released a few months later.	<u>Malfunkshun</u>	<u>1, 2, 4, 6, 7</u>

Tasks and Evaluation

- Open-ended QA
 - 다양한 도메인의 문서를 기반으로 질문을 직접 생성한 후 LLM-as-a-judge 방식으로 평가
 - GraphRAG 연구부터 페르소나 또는 시나리오에 맞춰 질문을 직접 생성하는 방식 차용되기 시작
 - 평가 지표: Comprehensiveness, Diversity, Empowerment, Overall 등

LightRAG(2025)에서 UltraDomain(2024) 문서를 바탕으로 질문을 생성한 프롬프트와 실제 질문

Given the following description of a dataset: **{total_description}**

Please identify **5 potential users** who would engage with this dataset. For each user, list **5 tasks** they would perform with this dataset. Then, for each (user, task) combination, generate **5 questions** that require a high-level understanding of the entire dataset.

Output the results in the following structure:

- **User 1:** [user description]
 - **Task 1:** [task description] [**Question 1:** {Question 1}, **Question 2:** {Question 2}, **Question 3:** {Question 3}, **Question 4:** {Question 4}, **Question 5:** {Question 5}]
 - **Task 2:** [task description] [**Question 1:** {Question 1}, **Question 2:** {Question 2}, **Question 3:** {Question 3}, **Question 4:** {Question 4}, **Question 5:** {Question 5}]
 - ...
 - **Task 5:** [task description] [**Question 1:** {Question 1}, **Question 2:** {Question 2}, **Question 3:** {Question 3}, **Question 4:** {Question 4}, **Question 5:** {Question 5}]
- **User 2:** [user description]
 - ...
- **User 5:** [user description]
 - ...

Query Generate Prompt

[Query]

- How do indigenous perspectives on ownership and collaboration influence corporate mergers in countries like Canada and Australia?
- Which methods can normalize the feature values for effective machine learning?

2

Paper Review



LightRAG: Simple and Fast Retrieval-Augmented Generation

Zirui Guo¹, Lianghao Xia¹, Yanhua Yu², Tu Ao², Chao Huang^{1*}


University of Hong Kong¹

Beijing University of Posts and Telecommunications²

zrguo101@hku.hk aka_xia@foxmail.com chaohuang75@gmail.com

Overview

- 지식 그래프 대상으로 dual-level 의 retrieval 을 통한 다각적 정보를 효율적으로 획득하는 방법론




Problem definition and Solutions

- 문제 정의
 - 기존 RAG 시스템의 한계
 - Entity 간의 관계를 기반한 정보 획득 어려움
 - 동일한 entity라도 다른 entity 와 다양한 종류 (inter)relation 존재하지만 이를 충분히 반영하지 못함
 - 더불어, 주제 간 연결도 찾을 수가 없음
 - Ex. 전기차 사용량의 증가가 대기 오염과 교통 체계에 주는 영향은?
 - 일반 RAG의 경우 : 전기차, 대기오염, 교통체계 각각에 대한 문서 반환
 - 그래프 대상 검색 시 그래프의 크기에 따라 비효율적일 수 있음
 - 해결 방안
 - Keyword 기반의 검색을 통해 서로 다른 entity 간 inter-dependent 한 그래프 정보를 빠르고 효율적으로 검색하여 반영하자
 - Comprehensive Information Retrieval / Enhanced Retrieval Efficiency & Rapid Adaptation to New Data

Method

• Graph-based Text Indexing

- Entity, Relationship 추출
- Entity와 relationship을 각각 K-V pair 로 표현
 - Entity = {Entity 이름 : 설명}
 - Relationship = {(src, tgt) : 설명}
- 중복되는 entity, relationship 제거



원문

Cardiologists assess symptoms to identify potential heart issues.

Entity
RelationshipEntity: Cardiologists, Heart Disease
Relationship: Cardiologists → diagnose → Heart Disease

[Cardiologists]

{"Cardiologists": "심장 전문의는 심장 관련 질환을 진단하고 치료하는 전문 의료인으로, 환자의 증상을 평가하여 잠재적인 심장 문제를 식별하는 역할을 한다."}

[Heart Disease]

{"Heart Disease": "심장 질환은 심장의 기능이나 구조에 영향을 미치는 다양한 질병을 포괄하며, 조기 증상 평가를 통해 발견될 수 있다."}


[Cardiologists → diagnose → Heart Disease]

{("diagnose", "symptom assessment") : "심장 전문의는 환자가 호소하는 증상을 체계적으로 평가함으로써 잠재적인 심장 질환을 식별한다. 이 진단 과정은 조기 발견과 치료 계획 수립에 핵심적인 역할을 한다."}

Method

• Dual-level Retrieval Paradigm

- 다음과 같이 다양한 종류의 사용자 질의를 모두 다룰 수 있어야 함
 - Specific : Who wrote 'Pride and Prejudice' ? ► **Low-level Retrieval**
 - Abstract : How does artificial intelligence influence modern education? ► **High-level Retrieval**
- 쿼리 자체를 분류하기 보다, 쿼리로부터 두 level의 키워드를 추출해서 모두 활용함



Method

- Dual-level Retrieval Paradigm (계속)

- 1) Query Keyword Extraction

---Role---

You are a helpful assistant tasked with identifying both high-level and low-level keywords in the user's query.

---Goal---

Given the query, list both **high-level** and **low-level** keywords. High-level keywords focus on overarching concepts or themes, while low-level keywords focus on specific entities, details, or concrete terms.

Keywords Generate Instruction Prompt

- Output the keywords in **JSON format**.
- The JSON should have two keys:
 - **"high_level_keywords"** for overarching concepts or themes.
 - **"low_level_keywords"** for specific entities or details.

-Examples-

Example 1:

Query: "How does international trade influence global economic stability?"

Output: {{ "high_level_keywords": ["International trade", "Global economic stability", "Economic impact"], "low_level_keywords": ["Trade agreements", "Tariffs", "Currency exchange", "Imports", "Exports"] }}

Example 2:

Query: "What are the environmental consequences of deforestation on biodiversity?"

Output: {{ "high_level_keywords": ["Environmental consequences", "Deforestation", "Biodiversity loss"], "low_level_keywords": ["Species extinction", "Habitat destruction", "Carbon emissions", "Rainforest", "Ecosystem"] }}

Example 3:

Query: "What is the role of education in reducing poverty?"

Output: {{ "high_level_keywords": ["Education", "Poverty reduction", "Socioeconomic development"], "low_level_keywords": ["School access", "Literacy rates", "Job training", "Income inequality"] }}

-Real Data-

Query: {query}

Output:

Keywords Generate Input Prompt

Method

- Dual-level Retrieval Paradigm (계속)

- 2) Keyword Matching

- Query keywords 들을 모두 연결하여 하나의 문자열로 만든 후 임베딩 획득
 - Local query keywords → Entity(노드)의 key + value 문자열의 임베딩 비교
 - Global query keywords → Relation 의 key + value 문자열의 임베딩과 비교
 - 특정 개수의 entity 와 relation 최종 검색 됨

Method

- Dual-level Retrieval Paradigm (계속)

- 3) Incorporating High-Order Relatedness

- 검색된 노드와 relation으로 구성된 subgraph의 정보 텍스트로 나열
- Entity의 출처가 되는 원문들도 포함 : 등장횟수가 높은 상위 원문들로 구성

실제 쿼리와 생성된 키워드와 검색된 문서의 예시

Query: What metrics are most informative for evaluating movie recommendation systems?

Query

High level keywords: ["Metrics", "Movie recommendation systems", "Evaluation methods"],

Low level keywords: ["Accuracy", "Precision", "Recall", "F1 score", "User satisfaction", "Diversity", "Coverage"]

Keywords

---Entities---

PERFORMANCE METRICS. Performance Metrics are measures used to evaluate how well the Decision Tree model performs, including RMSLE among others.

PRECISION-RECALL (PR) CURVE. The precision-recall curve is an event used to visualize the trade-off between precision and recall for different thresholds in binary classification.

MOVIE CLUSTERING. Movie clustering refers to the grouping of movies based on similarities using the K-means algorithm and evaluating their performance metrics.

ACCURACY. Accuracy is a basic metric used to assess the performance of predictive models, expressed as a percentage of correct predictions.

...

---Relationships---

ITEMMATRIX, MOVIES. ItemMatrix holds the factors for movies, used to derive recommendations for each user based on their preferences.

AVGPrecisionK, SPARK. avgPrecisionK function is utilized within the Spark framework to analyze the precision of recommendations for users.

MEAN SQUARE ERROR, VARIANCE. Mean Square Error is calculated based on the total Variance in the dataset, showing the relationship between explained and unexplained variance. + error measurement, variance

ACTUALMOVIES, PREDICTEDMOVIES. ActualMovies are compared against predictedMovies to assess the accuracy of the movie recommendation model

...

---Sources---

... these metrics are popular for model evaluation and selection purposes These movie IDs are sorted in order of the estimated rating.\nAs we did for MSE and RMSE, we can compute ranking-based evaluation metrics using MLib's 'RankingMetrics' class. Then, for each user, we have the list of actual and predicted movie IDs that we can pass to our APK function. In a manner similar to how we computed MSE, we will sum each of these APK scores using a 'reduce' action and divide by the number of users (that is, the count of the 'allRecs' RDD):\nFinally, we compute the accuracy for the decision tree..... First, we will compute the MSE and RMSE metrics using 'RegressionMetrics'. ...

Retrieval Context

Evaluation

- Research Questions

- 1) How does LightRAG compare to existing RAG baseline methods in terms of generation performance?
- 2) How do dual-level retrieval and graph-based indexing enhance the generation quality of LightRAG?
- 3) What are the costs associated with LightRAG, as well as its adaptability to data changes?

Evaluation

• Experimental Settings

• UltraDomain

- 총 18개 분야 및 428 개의 원서로 구성된 코퍼스
- Agriculture, Computer Science, Legal, Mix 총 4개 분야 선택함

• Query generation

- GraphRAG 방식 차용 : 5명의 사용자, 5개의 task, task 별 5개 질문 = 총 125개 질문 생성

Table 4: Statistical information of the datasets.

Statistics	Agriculture	CS	Legal	Mix
# Docs	12	10	94	61
# Tokens	2,017,886	2,306,535	5,081,069	619,009

Given the following description of a dataset: **{total_description}**

Please identify **5 potential users** who would engage with this dataset. For each user, list **5 tasks** they would perform with this dataset. Then, for each (user, task) combination, generate **5 questions** that require a high-level understanding of the entire dataset.

Output the results in the following structure:

- **User 1:** [user description]
 - **Task 1:** [task description] [**Question 1:** {Question 1}, **Question 2:** {Question 2}, **Question 3:** {Question 3}, **Question 4:** {Question 4}, **Question 5:** {Question 5}]
 - **Task 2:** [task description] [**Question 1:** {Question 1}, **Question 2:** {Question 2}, **Question 3:** {Question 3}, **Question 4:** {Question 4}, **Question 5:** {Question 5}]
 - ...
 - **Task 5:** [task description] [**Question 1:** {Question 1}, **Question 2:** {Question 2}, **Question 3:** {Question 3}, **Question 4:** {Question 4}, **Question 5:** {Question 5}]
- **User 2:** [user description]
- ...
- **User 5:** [user description]
- ...

Query Generate Prompt

Evaluation

- Experimental Settings
 - LLM-based Evaluation
 - 제안 방법론 v.s. others
 - GPT-4o-mini 활용
 - 임베딩 모델 확실치 않음
 - 코드 상
 - : bge-m3
 - : OpenAI(3-large)

---Role---

You are an expert tasked with evaluating two answers to the same question based on four criteria: **Comprehensiveness**, **Diversity**, and **Empowerment**.

---Goal---

You will evaluate two answers to the same question based on four criteria: **Comprehensiveness**, **Diversity**, and **Empowerment**.

- **Comprehensiveness**: How much detail does the answer provide to cover all aspects and details of the question?
- **Diversity**: How varied and rich is the answer in providing different perspectives and insights on the question?
- **Empowerment**: How well does the answer help the reader understand and make informed judgments about the topic?

For each criterion, choose the better answer (either Answer 1 or Answer 2) and explain why. Then, select an overall winner based on these three categories.

Evaluation Instruction Prompt

Here is the question: {query}

Here are the two answers: **Answer 1**: {answer1}; **Answer 2**: {answer2}

Evaluate both answers using the three criteria listed above and provide detailed explanations for each criterion.

Output your evaluation in the following **JSON format**:

```
{{
  "Comprehensiveness": {{ "Winner": "[Answer 1 or Answer 2]", "Explanation": "[Provide explanation here]" }},
  "Diversity": {{ "Winner": "[Answer 1 or Answer 2]", "Explanation": "[Provide explanation here]" }},
  "Empowerment": {{ "Winner": "[Answer 1 or Answer 2]", "Explanation": "[Provide explanation here]" }},
  "Overall Winner": {{ "Winner": "[Answer 1 or Answer 2]", "Explanation": "[Summarize why this answer is the overall winner based on the three criteria]" }}
}}
```

Evaluation Input Prompt



Evaluation

• RAG Performance Comparison (RQ1)

- Graph-based RAG >> 일반 RAG
 - 특히 corpus 크기 클수록 도드라짐
- 평가 지표 중 Diversity 가장 높음
- GraphRAG 대비 전반적으로 우수한 성능 보임
 - 그러나 Mix 데이터셋에서는 예외
- 발표자 의견
 - : Summary

Table 1: Win rates (%) of baselines v.s. LightRAG across four datasets and four evaluation dimensions.

	Agriculture		CS		Legal		Mix	
	NaiveRAG	LightRAG	NaiveRAG	LightRAG	NaiveRAG	LightRAG	NaiveRAG	LightRAG
Comprehensiveness	32.4%	<u>67.6%</u>	38.4%	<u>61.6%</u>	16.4%	<u>83.6%</u>	38.8%	<u>61.2%</u>
Diversity	23.6%	<u>76.4%</u>	38.0%	<u>62.0%</u>	13.6%	<u>86.4%</u>	32.4%	<u>67.6%</u>
Empowerment	32.4%	<u>67.6%</u>	38.8%	<u>61.2%</u>	16.4%	<u>83.6%</u>	42.8%	<u>57.2%</u>
Overall	32.4%	<u>67.6%</u>	38.8%	<u>61.2%</u>	15.2%	<u>84.8%</u>	40.0%	<u>60.0%</u>
	RQ-RAG	LightRAG	RQ-RAG	LightRAG	RQ-RAG	LightRAG	RQ-RAG	LightRAG
Comprehensiveness	31.6%	<u>68.4%</u>	38.8%	<u>61.2%</u>	15.2%	<u>84.8%</u>	39.2%	<u>60.8%</u>
Diversity	29.2%	<u>70.8%</u>	39.2%	<u>60.8%</u>	11.6%	<u>88.4%</u>	30.8%	<u>69.2%</u>
Empowerment	31.6%	<u>68.4%</u>	36.4%	<u>63.6%</u>	15.2%	<u>84.8%</u>	42.4%	<u>57.6%</u>
Overall	32.4%	<u>67.6%</u>	38.0%	<u>62.0%</u>	14.4%	<u>85.6%</u>	40.0%	<u>60.0%</u>
	HyDE	LightRAG	HyDE	LightRAG	HyDE	LightRAG	HyDE	LightRAG
Comprehensiveness	26.0%	<u>74.0%</u>	41.6%	<u>58.4%</u>	26.8%	<u>73.2%</u>	40.4%	<u>59.6%</u>
Diversity	24.0%	<u>76.0%</u>	38.8%	<u>61.2%</u>	20.0%	<u>80.0%</u>	32.4%	<u>67.6%</u>
Empowerment	25.2%	<u>74.8%</u>	40.8%	<u>59.2%</u>	26.0%	<u>74.0%</u>	46.0%	<u>54.0%</u>
Overall	24.8%	<u>75.2%</u>	41.6%	<u>58.4%</u>	26.4%	<u>73.6%</u>	42.4%	<u>57.6%</u>
	GraphRAG	LightRAG	GraphRAG	LightRAG	GraphRAG	LightRAG	GraphRAG	LightRAG
Comprehensiveness	45.6%	<u>54.4%</u>	48.4%	<u>51.6%</u>	48.4%	<u>51.6%</u>	<u>50.4%</u>	49.6%
Diversity	22.8%	<u>77.2%</u>	40.8%	<u>59.2%</u>	26.4%	<u>73.6%</u>	36.0%	<u>64.0%</u>
Empowerment	41.2%	<u>58.8%</u>	45.2%	<u>54.8%</u>	43.6%	<u>56.4%</u>	<u>50.8%</u>	49.2%
Overall	45.2%	<u>54.8%</u>	48.0%	<u>52.0%</u>	47.2%	<u>52.8%</u>	<u>50.4%</u>	49.6%

Evaluation

• Ablation Studies (RQ2)

- High-level 키워드 검색 삭제 시,
더 큰 성능 하락 발생
- - Origin : 실제 원문 제거
 - 오히려 간혹 성능 향상됨
 - 원문에 noise 가 포함되거나,
무관한 내용이 포함되어 있을 가능성
있음

Table 2: Performance of ablated versions of LightRAG, using NaiveRAG as reference.

	Agriculture		CS		Legal		Mix	
	NaiveRAG	LightRAG	NaiveRAG	LightRAG	NaiveRAG	LightRAG	NaiveRAG	LightRAG
Comprehensiveness	32.4%	<u>67.6%</u>	38.4%	<u>61.6%</u>	16.4%	<u>83.6%</u>	38.8%	<u>61.2%</u>
Diversity	23.6%	<u>76.4%</u>	38.0%	<u>62.0%</u>	13.6%	<u>86.4%</u>	32.4%	<u>67.6%</u>
Empowerment	32.4%	<u>67.6%</u>	38.8%	<u>61.2%</u>	16.4%	<u>83.6%</u>	42.8%	<u>57.2%</u>
Overall	32.4%	<u>67.6%</u>	38.8%	<u>61.2%</u>	15.2%	<u>84.8%</u>	40.0%	<u>60.0%</u>
	NaiveRAG	-High	NaiveRAG	-High	NaiveRAG	-High	NaiveRAG	-High
Comprehensiveness	34.8%	<u>65.2%</u>	42.8%	<u>57.2%</u>	23.6%	<u>76.4%</u>	40.4%	<u>59.6%</u>
Diversity	27.2%	<u>72.8%</u>	36.8%	<u>63.2%</u>	16.8%	<u>83.2%</u>	36.0%	<u>64.0%</u>
Empowerment	36.0%	<u>64.0%</u>	42.4%	<u>57.6%</u>	22.8%	<u>77.2%</u>	47.6%	<u>52.4%</u>
Overall	35.2%	<u>64.8%</u>	44.0%	<u>56.0%</u>	22.0%	<u>78.0%</u>	42.4%	<u>57.6%</u>
	NaiveRAG	-Low	NaiveRAG	-Low	NaiveRAG	-Low	NaiveRAG	-Low
Comprehensiveness	36.0%	<u>64.0%</u>	43.2%	<u>56.8%</u>	19.2%	<u>80.8%</u>	36.0%	<u>64.0%</u>
Diversity	28.0%	<u>72.0%</u>	39.6%	<u>60.4%</u>	13.6%	<u>86.4%</u>	33.2%	<u>66.8%</u>
Empowerment	34.8%	<u>65.2%</u>	42.8%	<u>57.2%</u>	16.4%	<u>83.6%</u>	35.2%	<u>64.8%</u>
Overall	34.8%	<u>65.2%</u>	43.6%	<u>56.4%</u>	18.8%	<u>81.2%</u>	35.2%	<u>64.8%</u>
	NaiveRAG	-Origin	NaiveRAG	-Origin	NaiveRAG	-Origin	NaiveRAG	-Origin
Comprehensiveness	24.8%	<u>75.2%</u>	39.2%	<u>60.8%</u>	16.4%	<u>83.6%</u>	44.4%	<u>55.6%</u>
Diversity	26.4%	<u>73.6%</u>	44.8%	<u>55.2%</u>	14.4%	<u>85.6%</u>	25.6%	<u>74.4%</u>
Empowerment	32.0%	<u>68.0%</u>	43.2%	<u>56.8%</u>	17.2%	<u>82.8%</u>	45.2%	<u>54.8%</u>
Overall	25.6%	<u>74.4%</u>	39.2%	<u>60.8%</u>	15.6%	<u>84.4%</u>	44.4%	<u>55.6%</u>

Evaluation

- Cost and Adaptability Analysis (RQ3)
 - Table3 : LLM 입출력 토큰 수 및 API 호출 횟수 현저히 낮음
 - Table 5,7 : 새로운 데이터(document)를 그래프에 추가 시 걸리는 시간 및 메모리 훨씬 적게 걸림
 - Table 6: Retrieval 시간도 현저히 적음

Table 3: RAG cost comparison on Legal data.

Phase	Retrieval Phase		Incremental Text Update	
Model	GraphRAG	Ours	GraphRAG	Ours
Tokens	$610 \times 1,000$	< 100	$1,399 \times 2 \times 5,000 + T_{\text{extract}}$	T_{extract}
API Calls	$\frac{610 \times 1,000}{C_{\text{max}}}$	1	$1,399 \times 2 + C_{\text{extract}}$	C_{extract}

Table 7: Final Storage Space Usage

Method	Final Storage Space (MB)
LightRAG	39.5
GraphRAG	286.7

Table 5: Comparison of Document Insertion Times

No.	Token Count	LightRAG (s)	GraphRAG (s)
1	59,870	486	642
2	41,224	418	700
3	73,989	561	953
4	47,502	513	741
5	48,353	453	926

Table 6: Average Query Times

Metric	LightRAG	GraphRAG
Average Query Time (s)	11.2	23.6

Take-aways

- 사용자 질의를 two-level의 키워드로 치환하여 검색하여 global + local + efficiency 모두 잘 포착함
 - 그래프 데이터를 다룰 때 global + local 정보의 활용은 주요 사항임
 - 기본적으로 query 를 구분한 후 진행되지만, 모든 쿼리를 global + local 관점으로 다 접근 가능하도록 한 점 인상깊음
 - 키워드 검색에 따라 비교적 디테일한 정보 보존도 가능할 것
- 지식 그래프 내 요소를 key-value 로 표현한 방법의 높은 유용성
 - 다만, 논문과 코드에서 간극 존재
 - 논문 : 쿼리로 부터 추출된 low-level 키워드와 entity 의 이름(key) 간의 비교
 - 코드 : entity 의 이름과 설명 (key+value) 대상으로 검색이 진행됨
- Research Question에 따른 실험을 깔끔히 잘 보여줌



The Fortieth AAAI Conference on Artificial Intelligence (AAAI-26)

LeanRAG: Knowledge-Graph-Based Generation with Semantic Aggregation and Hierarchical Retrieval

**Yaoze Zhang^{1,2*}, Rong Wu^{1,3*}, Pinlong Cai^{1†}, Xiaoman Wang⁴, Guohang Yan¹
Song Mao¹, Ding Wang¹, Botian Shi¹**

¹Shanghai Artificial Intelligence Laboratory


²University of Shanghai for Science and Technology

³Zhejiang University

⁴East China Normal University

Overview


- Flat 한 지식 그래프 내 entity 대상으로 hierarchical 클러스터링을 적용하여 상위 개념 간에도 모두 연결될 수 있도록 하자



Problem definition and Solutions

- 문제 정의


- GraphRAG: 여전히 large, coarse-grained community summary 들이 반환되어 중복적일 수 있으며 community summary 간 연결이 되어 있지 않음
- HiRAG(2025) : High-level summary 노드 간에는 연결이 없으며, retrieval 시 그래프 구조에 대한 정보가 잘 보존되지 않음



Problem definition and Solutions

- 해결 방안

- Hierarchical Graph Aggregation by Structured Retrieval via Lowest Common Ancestor (LCA)
- 지식 그래프 entity 대상의 클러스터링 이후 클러스터 간에도 연결을 통해 수직적, 수평적으로 정보를 획득하자
- 클러스터링을 통해 entity 정보가 반영된 hierarchical graph 형성



Method

- Hierarchical Knowledge Graph Aggregation
 - $H = \{G_0, G_1, \dots, G_k\} \mid G_i = (V_i, R_i, D_{(ver)_i}, D_{(rel)_i})$
 - Abstract view of the layer below G_{i-1}
 - Abstract entity, relationship 생성
 - $D_{(ver)}$: collection of entity descriptions | $D_{(rel)}$: collection of relationship descriptions
 - 최대 layer 수 = $\log_2 N + 1$
 - Recursive Semantic Clustering (G_{i-1} 대상)
 - $E_{i-1} = \{Emb(d_v) \mid v \in V_{i-1}\}$: 노드 description 대상의 임베딩 벡터 획득
 - Gaussian Mixture Clustering 활용 노드 임베딩 대상으로 m 개의 클러스터 형성 | $C_1, \dots, C_m$
 - Bayesian Information Criterion (BIC) 가 최소가 되는 m 설정

Method


- Generation of Aggregated Entities and Relations
 - Aggregated Entity Generation
 - α_j : 클러스터 C_j 를 대표하는 abstract entity
 - 클러스터 C_j 내 entities 와 relations 정보를 LLM에 입력하여 이름과 설명 획득 (프롬프트는 공식 github에서 확인)

Method

- Generation of Aggregated Entities and Relations


- Aggregated Relation Generation (본 연구의 핵심)

- 기본 지식 그래프 내 relationship 표기 방식 = *"relationship</>{SBJ}</>{OBJ}</>{DESCRIPTION}"*
- 아래의 예시 중 서로 다른 클러스터 내 노드 간 관계 존재 시 (r_{32}, r_{45})
 - 모든 Relationship 표기 토큰 수 << 특정 기준(hyper-parameter) = 단순 연결 함
 - 모든 Relationship 표기 토큰 수 >> 특정 기준(hyper-parameter) = LLM 이용하여 새로 산출



Method

- Structured Retrieval via Lowest Common Ancestor
 - Initial Entity Anchoring
 - 노드(엔티티) 임베딩 기반 상위 n개 선택 = Seed entities
 - Contextualization via LCA Path Traversal
 - 기본(Flat) 지식 그래프 상에서 서로 다른 노드를 연결하는 경로 상당히 많을 수 있음
 - 따라서, 계층적 지식 그래프 상에서 seed entities 를 모두 연결하는 subgraph를 Lowest Common Ancestor (LCA) 기법으로 찾아내자
 - 의미적으로 중복을 최소화 할 수 있음
 - 모든 경로 내 entity, relationship, entity 의 출처 원문들(chunk) 을 모두 context 로 활용
 - 많이 등장한 출처 원문들 상위 몇 개만 선택함 (hyper-parameter)



Experiments

- Research Questions
 - RQ1: How does LeanRAG's QA performance compare against state-of-the-art baselines across diverse domains?
 - RQ2: Does LeanRAG's retrieval strategy reduce redundancy while improving generation quality?
 - RQ3: To what extent does the explicit generation of relations between aggregated entities contribute to the quality of the response?
 - RQ4: Is the structured knowledge retrieved from the graph sufficient for high-quality generation, or is the inclusion of the entities original textual context essential?

Experiments

- Datasets and Evaluation Metrics
 - LightRAG와 동일한 데이터셋과 평가지표 활용 ([바로가기](#))
 - 평가 시 DeepSeek-V3 활용
 - 서로 다른 5번의 답안에 대한 각 평가 기준 별 score (1-10점)의 평균 값 비교
- Implementation Details
 - Answer Generation = DeepSeek-V3
 - Text Embedding Retrieval = BGE-M3

Experiments


- Overall Performance Comparison (RQ1)
 - HiRAG 를 포함하여 계층적 그래프 활용 시 더 효과적인 결과 보여줌

Dataset	Metric ↑	LeanRAG	HiRAG	Naive	GraphRAG	LightRAG	FastGraphRAG	KAG
Mix	Comprehensiveness	8.89±0.01	8.72±0.02	8.20±0.01	8.52±0.01	8.19±0.02	6.56±0.02	7.90±0.03
	Empowerment	8.16±0.02	7.86±0.03	7.52±0.03	7.73±0.02	7.56±0.03	5.82±0.03	7.41±0.04
	Diversity	7.73±0.01	7.21±0.02	6.65±0.03	7.04±0.02	6.69±0.04	4.88±0.03	6.42±0.04
	Overall	8.59±0.01	8.08±0.02	7.47±0.02	7.87±0.01	7.61±0.04	5.76±0.02	7.25±0.03
CS	Comprehensiveness	8.92±0.01	8.92±0.01	8.94±0.01	8.55±0.02	8.76±0.02	6.79±0.01	8.22±0.02
	Empowerment	8.68±0.02	8.66±0.02	8.69±0.04	8.28±0.04	8.50±0.04	6.67±0.04	8.52±0.05
	Diversity	7.87±0.02	7.84±0.02	7.79±0.02	7.42±0.02	7.63±0.04	5.45±0.04	7.03±0.02
	Overall	8.82±0.02	8.77±0.02	8.77±0.03	8.37±0.04	8.59±0.04	6.31±0.03	7.99±0.03
Legal	Comprehensiveness	8.88±0.02	8.68±0.02	8.85±0.01	8.95±0.01	8.24±0.02	3.87±0.02	8.41±0.02
	Empowerment	8.42±0.03	8.18±0.06	8.28±0.03	8.33±0.02	7.83±0.05	3.53±0.03	8.20±0.03
	Diversity	7.49±0.03	7.00±0.03	7.10±0.04	7.47±0.03	6.87±0.01	2.87±0.02	6.71±0.01
	Overall	8.49±0.04	8.00±0.04	8.21±0.03	8.44±0.01	7.74±0.03	3.43±0.02	7.83±0.03
Agriculture	Comprehensiveness	8.94±0.06	8.99±0.00	8.85±0.01	8.97±0.01	8.71±0.01	3.28±0.01	8.22±0.01
	Empowerment	8.66±0.02	8.52±0.02	8.51±0.03	8.52±0.02	8.23±0.02	3.29±0.05	8.33±0.06
	Diversity	8.06±0.03	7.98±0.02	7.76±0.06	7.95±0.02	7.68±0.03	3.01±0.03	7.07±0.02
	Overall	8.87±0.02	8.87±0.03	8.69±0.03	8.85±0.01	8.56±0.02	3.17±0.02	7.95±0.03

Table 1: Evaluation scores (1–10 scale) of LeanRAG compared to baseline methods, assessed by an LLM

Experiments

- Analysis of Information Redundancy (RQ2)
 - 평가 방식: 검색되는 context 의 토큰 수가 적을수록 중복되는 내용이 없을 것 | Qwen3-14B로 평가 진행
 - 즉, 경제적으로 필요한 내용만 잘 검색해 냈을 보여주는 실험 | 방법론의 'Lean' 을 뒷받침하는 결과
 - 비교적 긴 길이의 LightRAG의 context



Experiments

- Cluster Relation Effectiveness Analysis (RQ3) - 본 방법론의 핵심 평가
 - Abstract entity 간 relation 제거 시 성능 하락
 - 특히, Diversity 측면에서의 하락 폭이 가장 큼

	Mix		CS		Legal		Agriculture	
Comprehensiveness	51.5%	48.6%	54.5%	45.5%	55.5%	44.5%	54.0%	46.0%
Empowerment	55.0%	45.0%	55.5%	44.5%	56.5%	43.5%	59.5%	40.5%
Diversity	59.6%	40.4%	66.0%	34.0%	57.0%	43.0%	63.0%	37.0%
Overall	53.8%	46.2%	58.5%	41.5%	56.5%	43.5%	58.0%	42.0%

Table 2: Win rates (%) between LeanRAG and LeanRAG w/o Relation (Left: LeanRAG; Right: w/o Relation)

Experiments

- Necessity Analysis of Textual Context (RQ4)
 - Corpus 의 원문이 없어도 지식 그래프 및 계층 그래프의 내용만으로도 충분한지 를 평가
 - 결과적으로, Corpus 의 원문이 필요함
 - 구조적 정보는 graph retrieval, 실제 내용은 원문 chunk 로부터 획득하여 두 정보를 잘 융합함

Dataset	Metric ↑	LeanRAG	LeanRAG w/o Context
Mix	Comprehensiveness	8.89±0.01	8.15±0.02 ↓
	Empowerment	8.16±0.02	7.80±0.01 ↓
	Diversity	7.73±0.01	7.26±0.02 ↓
	Overall	8.59±0.01	7.93±0.01 ↓
CS	Comprehensiveness	8.92±0.01	8.66±0.02 ↓
	Empowerment	8.68±0.02	8.19±0.03 ↓
	Diversity	7.87±0.02	7.57±0.02 ↓
	Overall	8.82±0.02	8.34±0.02 ↓
Legal	Comprehensiveness	8.88±0.02	8.49±0.01 ↓
	Empowerment	8.42±0.03	8.11±0.04 ↓
	Diversity	7.49±0.03	7.09±0.04 ↓
	Overall	8.49±0.04	8.00±0.04 ↓
Agriculture	Comprehensiveness	8.94±0.06	8.65±0.01 ↓
	Empowerment	8.66±0.02	8.16±0.05 ↓
	Diversity	8.06±0.03	7.88±0.05 ↓
	Overall	8.87±0.02	8.53±0.03 ↓

Table 3: Necessity analysis of textual context

Take-aways

- 평면적 지식 그래프를 계층적으로도 잘 확장시킨 방법론
 - 그래프의 local + global 정보 탐색에 적합한 방법론
 - GraphRAG의 community summary 를 비교적 lean 하게 표현한 방법론
 - Lowest Ancestor Common 결과 도 함께 제공되었으면 어땠을까
- 효율성 비교 평가 부재
 - 추론 시간의 비교 실험 부재 - 아마 비교적 추론 시간이 비교적 오래 걸리지 않았을까 예상됨
 - Hierarchical 그래프 는 초기에 구축 가능함
 - LCA 탐색 소요 시간이 관건일 듯

3

Conclusion

Graph-based RAG

- Graph retrieval 의 핵심
 - 구조 정보를 어떻게 잘 & 효과적으로 찾고, 반영할 것인가
 - Local + Global 정보를 얼마나 잘 융합하여 포착하는 가
 - GraphRAG에서 처럼 community summary 활용 시에는 디테일한 정보 파악이 어려움
 - LightRAG에서 처럼 개별적인 entity 와 relation 을 나열하는 것 만으로도 일정 수준의 효과 보임
 - 만약 corpus 로 부터 추출한 것이 아닌 고정된 지식 그래프에 대해서는 어떤 방법이 효과적일까?
 - 즉, 지식 그래프 요소의 원문이 부재한 상황에서는 어떻게 해야 할까?
 - 혹은, 지식 그래프가 아닌 일반적인 그래프에 대해서는 어떠한 retrieval 이 효과적일까?
 - 발표자 경험 상, 새로운 데이터를 기존의 그래프에 추가하는 데에는 비교적 적은 time/cost 소요됨
 - 검색 후 context 화 과정에서의 소요 시간이 전체의 대부분

EOD